

人工知能(AI)テクノロジーデザインⅠ 第1回

グループワーク 穴埋めスライド

GW1 AIは何を学習するのか / GW2 ディープラーニングプログラミングの流れ

グループ番号：

メンバー（役割）：implementer / verifier / recorder / presenter

使い方：黄色の欄を埋める。灰色・緑色のチップは表の欄へドラッグして貼る。
スライドの複製は presenter が行い、記録は recorder が担当する。答え合わせは最後のスライドにある（先に見ない）。

GW1-1 AIの3つのアプローチ — 表を完成させる（10分）

「どこに注目するか（特徴量）」と「どう判定するか（判定ルール）」を，人が作るのか，データから学習するのか，右のチップを表に貼り，空欄を埋める。

アプローチ	主な時期	特徴量 (どこに注目するか)	判定ルール (どう判定するか)	代表的な手法	チップ（ドラッグして貼る）
ルールベース					人が設計
従来の機械学習 (統計的機械学習)					人が設計
深層学習 (深層ニューラルネットワーク)					人が設計
					データから学習
					データから学習
					データから学習
					データから学習

※ 深層学習の行は，特徴量と判定ルールの 2 欄を 1 つとして考えてよい

- 問い (1) 「人が設計」から「データから学習」へ移ったのは，表のどの欄が先か。
(2) 深層学習でも人が決めているものは何か（3つ）。
(3) 3つのアプローチは置き換わったのか，使い分けられているのか，身近な例を1つ挙げる。

GW1-2 画像分類の例で考える ― この写真をどう判定するか（10分）

3つのアプローチそれぞれで、「何を見て」「どう決めるか」を自分たちの言葉で書く。右端にはそのやり方の弱点を書く。



入力データ（フクロウの写真）

ルールベース

人が特徴量と判定ルールを記述する

if-then ルールを書く：
「_____」かつ「_____」 → フクロウ

弱点：

従来の機械学習

特徴量は人が設計、分類器はデータから学習

特徴量（人が設計）：

分類器（データから学習）：

弱点：

深層学習

特徴量の抽出と分類をまとめて学習

何を学習するか：

弱点：

GW2-1 プログラミングの流れー カードを3つのフェーズに並べる (10分)

下の12枚のカードを、正しい順に上の枠へドラッグする。番号は書いていない。並べたあと、各フェーズの見出しも埋める。

データ準備フェーズ

学習設定フェーズ

学習, 評価フェーズ

損失関数の定義

ネットワークの定義

ライブラリのインポート

データの前処理

モデル学習&検証

学習結果の可視化

デバイスの設定

最適化関数の定義

データセットの準備

データローダの作成

モデル性能評価

入力データの形状確認

- 問い (1) 「学習」が始まるのは何番目のカードからか。それより前は何をしているか。
(2) データが画像からテキストに変わったとき、差し替えるカードはどれか。

GW2-2 入力データはどんなテンソルになるか（5分）

どんなデータも「前処理で数値化 → テンソル → ディープラーニングモデル → 出力」の同じ流れに乗る。今日扱う2つの行を必ず埋め、残りは分かる範囲で埋める。

入力データ	前処理（数値化）	テンソルの形状（例）
画像（今日：FashionMNIST）		
テキスト（今日：SST-2 映画レビュー）		
数値データ（表形式）		
音声		
時系列（加速度センサ）		

ディープラーニングモデル
（多層ニューラルネットワーク）

層を重ねて、入力テンソルから特徴表現を段階的に抽出する。

学習：予測と正解の誤差を損失関数で測り、誤差逆伝播で重み（パラメータ）を更新する。

- 問い (1) Nは何を表すか。今日の演習で Nを変えると何が変わるか（時間？正解率？）。
- (2) 画像とテキストで「モデルに入る直前の形状」はどう違うか。それでも同じ学習ループで回るのはなぜか。

答え合わせ：GW1-1 AIの3つのアプローチ

アプローチ	主な時期	特徴量 (どこに注目するか)	判定ルール (どう判定するか)	代表的な手法
ルールベース	1950～80年代 第1次AIブーム（推論・探索） 第2次AIブーム（知識表現）	人が設計	人が作成 (if-then ルールなど)	探索アルゴリズム， エキスパートシステム
従来の機械学習 (統計的機械学習)	1990～2000年代	人が設計 (SIFT，HOG など)	データから学習	SVM，k近傍法， 決定木，ロジスティック回帰
深層学習 (深層ニューラルネットワーク)	2010年代～ 第3次AIブーム	データから学習 特徴量と判定ルールを同時に学習する		CNN，RNN， Transformer

※ 第3次AIブームは2000年代以降の機械学習全般の発展を含み，2012年頃からの深層学習の成功で本格化した．時期は目安である．

※ 深層学習でも，モデルの構造，損失関数，学習データは人が決める．データから学習するのは，その枠組みの中の重み（パラメータ）である．


※ 3つのアプローチは完全に置き換わったのではなく，現在も用途に応じて使い分けられている．

答え合わせ：GW1-2 画像分類の例

AIの3つのアプローチ（画像分類の例）

違いは「どこに注目するか（特徴量）」と「どう判定するか（判定ルール）」を，人が作るか，データから学習するか

□ 人が設計 □ データから学習




※ 右列の例は傾向を示すイメージであり，実際の精度はデータ量やタスクによって異なる．3つのアプローチは完全に置き換わったのではなく，現在も用途に応じて使い分けられている．

※ 深層学習でも，モデルの構造，損失関数，学習データは人が決める．データから学習するのは，その枠組みの中の重み（パラメータ）である．


答え合わせ：GW2-1 ディープラーニングプログラミングの流れ

ディープラーニングプログラミングの流れ



答え合わせ：GW2-2 テンソルの形状

入力データ	前処理（数値化）	テンソルの形状（例）
数値データ（表形式）	欠損処理・標準化	(N, 特徴量数)
テキスト	トークン化→ID列→埋め込み	(N, トークン数, 埋め込み次元)
音声	サンプリング／スペクトログラム化	(N, サンプル数) / (N, 1, 周波数, 時間)
画像	画素値の正規化・リサイズ	(N, チャンネル, 高さ, 幅)
動画	フレーム抽出	(N, フレーム数, チャンネル, 高さ, 幅)
3D：点群／メッシュ	座標の正規化・点の抽出	(N, 点数, 3) ／ 頂点(V,3)+面(F,3)
グラフ	ノード特徴・接続関係の数値化	ノード特徴(ノード数, D)+隣接行列
時系列	窓切り出し・標準化	(N, 時間ステップ数, 変数数)



※ N はバッチサイズ（まとめて処理するデータ数）。形状は代表例であり、次元の並び順はフレームワークやモデルによって異なる（例：PyTorch の画像は (N, C, H, W)，TensorFlow は (N, H, W, C)）。グラフやメッシュは単一のテンソルではなく、複数のテンソルの組で表現する。